NASLOV PROJEKTNOG ZADATKA:	*Predikcija kretanja cijena dionica i generiranje buy/sell signala*
KOLEGIJ:	*Primijenjeno strojno učenje*
IME I PREZIME STUDENTA:	*Niko Šimičić*
AKADEMSKA GODINA:	*2025./2026.*
NAPOMENA:	Vlastito definirana tema.

SADRŽAJ

1. UVOD 3
2. DEFINIRANJE PROBLEMA 4
2.1. Skup dionica i cross-asset pristup 4
3. SKUP PODATAKA 5
3.1. Izvor podataka 5
3.2. Tehnički indikatori 5
3.3. Podjela skupa podataka 5
3.4. Ravnoteža klasa 5
4. METODE I ALGORITMI 6
4.1. Pregled modela 6
4.2. LSTM arhitektura 6
4.3. Grid search i optimizacija strategije 6
4.4. Backtest strategija 6
5. PREDLOŽENO RJEŠENJE ZA PREDIKCIJU SMJERA KRETANJA CIJENA DIONICA 8
5.1. Arhitektura sustava 8
5.1.2. Inženjering obilježja (indicators.py) 8
5.1.3. Cross-asset skup obilježja (train_models.py: build_cross_asset_dataset) 8
5.1.4. Podjela podataka i unakrsna validacija 8
5.1.5. Modeli strojnog učenja 8
5.1.6. Optimizacija strategija – grid search 8
5.1.7. Backtest 8
5.1.8. Streamlit aplikacija (app.py) 8
6. EVALUCIJA PREDLOŽENOG RJEŠENJA 9
6.1. Unakrsna validacija (trening skup) 9
6.2. Usporedba modela na testnom skupu 9
6.3. Rezultati backtestinga 9
6.4. Važnost obilježja po dionici (XGBoost) 10
7. ZAKLJUČAK 11

1. UVOD

Ovaj projektni zadatak bavi se predikcijom smjera kretanja cijene dionica primjenom metoda strojnog učenja. Cilj ovog projekta je binarna klasifikacija, predvidjeti hoće li cijena dionice Apple Inc. (AAPL) narasti ili pasti sljedeći trgovački dan. Skup podataka obuhvaća desetogodišnje dnevne povijesne podatke za sedam tehnoloških dionica ili Magnificent Seven (AAPL, MSFT, GOOGL, AMZN, TSLA, NVDA, META), iz kojih se računaju tehnički indikatori. Implementiran je sustav višedioničnih (cross-asset) obilježja s ukupno 70 ulaznih varijabli, odnosno po 10 tehničkih indikatora za svaku dionicu. Ispitano je pet modela klasifikacije: logistička regresija, višeslojni perceptron (MLP), SVM, Random Forest i XGBoost, te duboki rekuretni model (LSTM). Najboljim modelom pokazao se XGBoost s točnošću 55% na testom skupu i Sharpeovima omjerom strategije od 2,00. Uspoređene su dvije strategije backtestinga: binarna strategija (100% kapital ili gotovina) i strategija veličine pozicije (P(up) kao udio kapitala). Rezultati govore da je, uz ograničenje hipoteze o učinkovitim tržištima, moguće ostvariti statistički značajan signal za aktivno upravljanje rizikom.

2. DEFINIRANJE PROBLEMA

Predikcija kretanja cijena dionica je jedan od klasičnih problema strojnog učenja u financijama. Hipoteza o učinkovitim tržištima (Efficient Market Hypothesis, EMH) tvrdi da su sve javno dostupne informacije već u cijeni dionice, što dodatno otežava predikciju. Međutim, kratkoročni obrasci (patterns) u tehničkim indikatorima sadržavaju statistički dobar signal.

Problem je formuliran kao binarna klasifikacija za svaki trgovački dan t:

$$y(t) = 1 \text{ ako je } Close(t+1) > Close(t), \text{ inače } y(t) = 0 \quad (2\text{-}1)$$

Model na temelju tehničkih indikatora izračunatih na dan t predviđa binarnu oznaku y(t), tj. Smjer kretanja cijna sljedećeg dana. Nema uvida u buduće podatke, odnosno oznake su poznate jedino u treniranju, jer se radi na povijesnim podacima.

2.1. Skup dionica i cross-asset pristup

Jedan od dobrih pristupa kasnije implementiranih je cross-asset, dakle umjesto treniranja isključivo na jednoj dionici, sustav koristi sedam tehnološki korelirajućih dionica ili Magnificent Seven: AAPL, MSFT, GOOGL, AMZN, TSLA, NVDA i META. Svaka dionica pridonosi tehničkim indikatorima koji zajedno opisuju opće stanje tehnološkog sektora. Model uči kako ponašanje korelirajućih dionica na dan t predviđa pomak AAPL dionice sljedećeg dana ili cross-asset pristup.

3. SKUP PODATAKA

3.1. Izvor podataka

Dnevni podaci (Open, High, Low, Close, Volume) preuzimaju se automatski putem biblioteke yfinance za period od 10 godina za svih 7 dionica. Za svaku dionicu dobiva se 2514 redaka. Nakon spajanja svih dionica po datumu (inner join, zadržavaju se samo dani kada su sve dionice imale promet) i izračuna tehničkih indikatora, finalni skup sadrži 2494 redaka i 70 featuresa.

3.2. Tehnički indikatori

Za svaku od 7 dionica izračuna se 10 tehničkih indikatora:

- RSI_14: Relative Strength Index (14 dana) - Wilderov EWM
- MACD: Moving Average Convergence Divergence (12/26 EMA razlika)
- Signal_Line: 9-dnevni EMA MACD signalne linije
- MACD_Histogram: Razlika MACD i signalne linije
- Daily_Return: Dnevni prinos: (Close_t – Close_{t-1})/Close_{t-1}
- Volatility_20: Standardna devijacija dnevnih prinosa (20 dana)
- Price_vs_EMA_20: Close/EMA_20 – relativan odmak od kratkoročnog trenda
- Price_vs_SMA_20: Close/SMA_20 – relativan odmak od SMA
- Return_5: Prinos za 5 dana
- Volume_change: Relativna promjena volumena

Budući da se indikatori računaju za 7 dionica, ukupan broj ulaznih obilježja iznosi 70. Svako obilježje nosi prefiks dionice (npr. AAPL_RSI_14)

3.3. Podjela skupa podataka

Zbog vremenske ovisnosti financijskih podataka, koristi se kronološka podjela bez miješanja podataka:

Skup	Udio	Broj primjera	Namjena
Trening	80 %	1995	Treniranje modela
Validacija	10 %	249	Grid search
Test	10 %	250	Završna evaluacija — nikad se ne gleda unaprijed

3.4. Ravnoteža klasa

U skupu AAPL podataka registrirano je 1338 dana rasta (klasa 1, BUY) i 1156 dana pada (klasa 0, SELL/HOLD), što daje blagu neuravnoteženost (54%:46%). Kako bi se izbjegla pristranost prema većinskoj klasi BUY, koristi se class_weight='balanced' u modelima koji to podržavaju (logistička regresija, SVM, Random Forest).

4. METODE I ALGORITMI

4.1. Pregled modela

U ovom projektu ispitano je šest modela. Pet klasičnih ML modela implementirano je unutar scikit-learn Pipeline-a koji uključuje standardizaciju obilježja uz pomoć StandardScaler-a tamo gdje je potrebno:

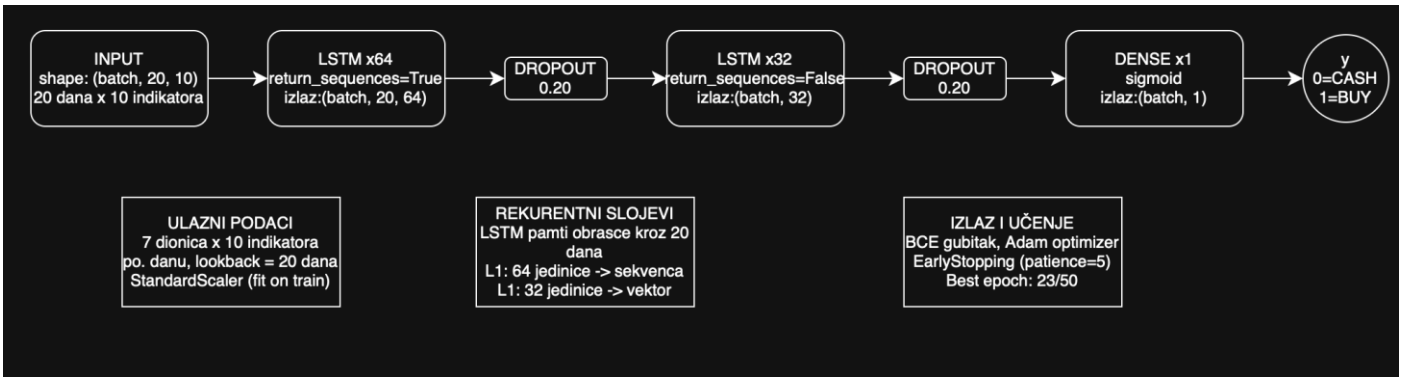
Model	Hyperparameters
Logistička regresija	max_iter=1000, class_weight='balanced'
MLP	hiddenLayers=(64,32), early_stopping=True, max_iter=1000
SVM (RBF)	C=1.0, class_weight='balanced'
Random Forest	n_estimators=100, max_depth=5, balanced_subsample
XGBoost	n_estimators=200, max_depth=3, lr=0.05, subsample=0.8
LSTM	2 sloja (64, 32), Dropout(0.2), lookback=20, EarlyStopping(p=5)

4.2. LSTM arhitektura

LSTM model prima sekvence od 20 uzastopnih dana (LOOKBACK=20). Za svaki dan ulazni vektor sadrži 10 tehničkih indikatora AAPL dionice (standardiziranih FitOnly-on-train scalerom).

Arhitektura:

Trening je proveden nad sekvencama 7 dionica. Model se trenirao trenirao 28 epoha (od maksimalno 50), pri čemu je EarlyStopping zaustavio treniranje jer validacijski gubitak nije se poboljšavao 5 uzastopnih epoha od epohe 23 (gdje je minimalni val_loss = 0.6564).



4.3. Grid search i optimizacija strategije

Za svaki model koji se koristi u backtestingu provodi se grid search na validacijskom skupu.

Pretražuju se kombinacije:

- Prag odluke (threshold): [0,45; 0,50; 0,55, 0,60]
- EMA filter: [EMA_20] (EMA_50 isključen jer ostaje elevated dugo nakon pada tržišta)
- Minimalni period držanja pozicije (hold): [1, 3, 5 dana]

Optimizacijska metrika je Sharpeov omjer na validacijskom skupu. Strategije koje generiraju nula kažnjavaju se s Sharpe=-inf, čime se osigurava da grid search uvijek preferira aktivnu strategiju, a ne pasivnu.

4.4. Backtest strategija

U projektu implementirane su dvije strategije za ocjenu ekonomske korisnosti modela:

Binarna strategija: signal = 1 (BUY) ako P(up) > prag i Close > EMA_20; inače signal = 0 (CASH). Kapital je ili 100% uložen ili 100% u gotovini. Pozicija se osvježava po isteku minimalnog perioda držanja.

Strategija veličine pozicije (Position Sizing): udio kapitala = P(up) ako Close > EMA_20; inače 0. Nema praga ni minimalnog perioda držanja, model kontinuirano skalira izloženost tržištu prema svojoj pouzdanosti.

Obje strategije primjenjuju pomak pozicije za jedan dan (shift-by-1) kako bi se izbjegao look-ahead bias, a predikcija dana t primjenjuje se na povrat dana t+1.

5. PREDLOŽENO RJEŠENJE ZA PREDIKCIJU SMJERA KRETANJA CIJENA DIONICA

Predloženo rješenje jest automatizirani sustav za binarnu klasifikaciju smjera kretanja cijene dionice koji objedinjuje preuzimanje financijskih podataka, inženjering obilježja, treniranje više modela strojnog učenja, optimizaciju strategije i simulaciju trgovanja. Sustav je implementiran u programskom jeziku Python i organiziran u modularne komponente, a rezultati su dostupni putem interaktivne web-aplikacije.

5.1. Arhitektura sustava

5.1.1. Preuzimanje podataka (fetch_data.py)

Dnevni podaci (Open, High, Low, Close, Volume) preuzimaju se automatski putem biblioteke yfinance za sedam tehnoloških dionica: AAPL, MSFT, GOOGL, AMZN, TSLA, NVDA i META, za period od 10 godina. Podaci se cache-aju kako bi se izbjeglo ponavljano preuzimanje.

5.1.2. Inženjering obilježja (indicators.py)

Za svaku dionicu izračuna se 10 tehničkih indikatora: RSI_14, MACD, Signal_Line, MACD_Histogram, Daily_Return, Volatility_20, Price_vs_EMA_20, Price_vs_SMA_20, Return_5 i Volume_change. SMA i EMA vrijednosti računaju se kao međukoraci, u skup obilježja ulaze isključivo njihovi normalizirani omjeri (Price_vs_EMA_20, Price_vs_SMA_20) kako bi obilježja bila stacionarna i usporediva između dionica različitih cjenovnih razina.

5.1.3. Cross-asset skup obilježja (train_models.py: build_cross_asset_dataset)

Obilježja svih 7 dionica spajaju se po datumu (inner join), čime nastaje matrica od 70 ulaznih varijabli po danu. Svako obilježje nosi prefiks dionice (npr. META_RSI_14, MSFT_MACD). Ciljna varijabla je smjer kretanja AAPL dionice sljedećeg dana: 1 ako Close(t+1) > Close(t), inače 0. Konačni skup sadrži 2494 primjera i 70 obilježja.

5.1.4. Podjela podataka i unakrsna validacija

Podaci se dijele kronološki u omjeru 80/10/10 (trening/validacija/test) bez ikakvog miješanja, čime se sprječava curenje budućih informacija u prošlost. Unakrsna validacija provodi se metodom TimeSeriesSplit s 5 preklopa isključivo na trenirnom skupu.

5.1.5. Modeli strojnog učenja

Implementirano je i ispitano šest modela:

- Logistička regresija (linearni bazni model)
- MLP (64, 32 neurona, EarlyStopping)
- SVM s RBF jezgrom
- Random Forest (100 stabala, max_depth=5)
- XGBoost (200 stabala, learning_rate=0,05)
- LSTM (2 rekurentna sloja — 64 i 32 jedinice, Dropout=0,2, lookback=20 dana)

Svi modeli koji podržavaju uravnoteženje klasa koriste class_weight='balanced' zbog blage neuravnoteženosti skupa (54 % BUY : 46 % SELL).

5.1.6. Optimizacija strategija – grid search

Na validacijskom skupu provodi se pretraga po mreži (grid search) kombinacijom praga odluke (0,45–0,60), EMA filtera trenda i minimalnog perioda držanja pozicije (1, 3 ili 5 dana). Optimizacijska metrika je Sharpeov omjer — strategije bez ijedne transakcije kažnjavaju se vrijednošću $-\infty$.

5.1.7. Backtest

Na testnom skupu ispituju se dvije strategije:

- Binarna strategija: kapital je u potpunosti uložen (BUY) ili u gotovini (CASH), ovisno o tome prelazi li P(up) postavljeni prag uz uvjet da je cijena iznad EMA_20.
- Position Sizing: udio uloženog kapitala jednak je P(up) po modelu, uz isti EMA filter. Nema fiksnog praga ni minimalnog perioda držanja.

Obje strategije primjenjuju pomak pozicije za jedan dan (shift-by-1) kako bi se izbjegao look-ahead bias.

5.1.8. Streamlit aplikacija (app.py)

Interaktivna web-aplikacija s četiri kartice: istraživačka analiza podataka (EDA), usporedba modela, backtest s vizualizacijom i live signal za zadnji dostupni dan. Modeli se cash-aju nakon prvog treniranja (@st.cache_resource).

6. EVALUCIJA PREDLOŽENOG RJEŠENJA

6.1. Unakrsna validacija (trening skup)

Rezultati TimeSeriesSplit unakrsne validacije na trening skupu pokazuju vrijednosti bliske 50%, što je konzistetno s hipotezom o učinkovitim tržištima.

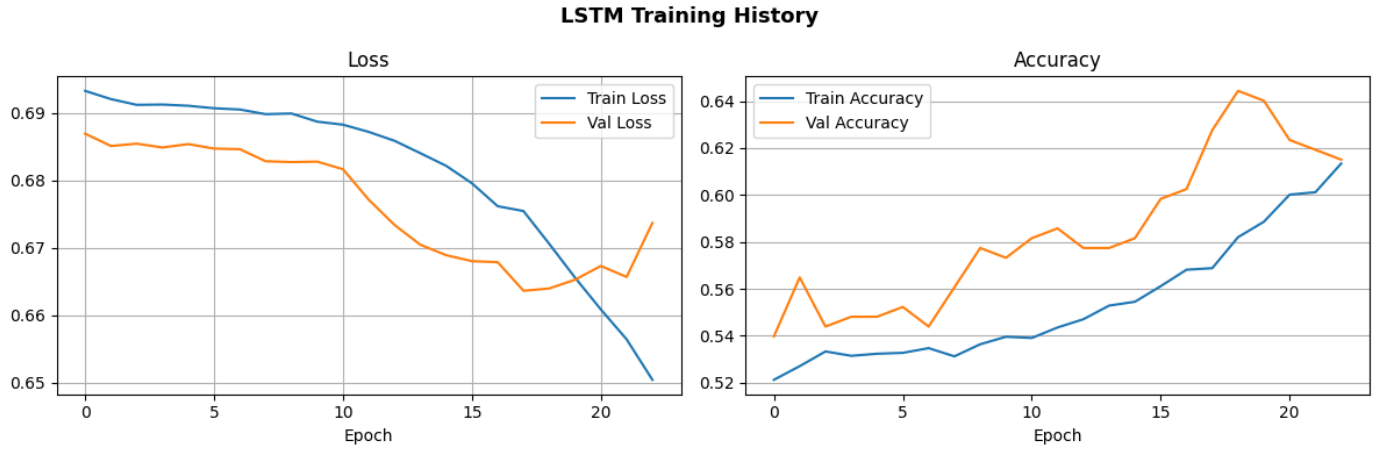
Model	CV Točnost (mean ± std)
Logistička regresija	0,501 ± 0,028
MLP	0,514 ± 0,022
SVM	0,490 ± 0,033
Random Forest	0,508 ± 0,013
XGBoost	0,502 ± 0,022

6.2. Usporedba modela na testnom skupu

Evaluacija na testnom skupu (250 primjera, lipanj 2025. - svibanj 2026.):

Model	Accuracy	Precision(BUY)	Recall (BUY)	F1 (BUY)
Logistic regression	0,488	0,523	0,507	0,515
MLP	0,472	0,506	0,649	0,569
SVM	0,452	0,452	0,104	0,170
Random Forest	0,500	0,526	0,687	0,595
XGBoost	0,528	0,539	0,828	0,653
LSTM	0,53	0,55	0,63	0,59

Najboljim modelom po točnosti na testnom skupu pokazao se LSTM (53,0%), marginalno ispred XGBoost modela (52,8%). Međutim, razlika od 0,2% nije statistički značajna na uzorku od 240 primjera, a LSTM rezultati variraju između pokretanja. XGBoost ima i F1 ocjenu za klasu BUY (0,653). Dakle LSTM pokazuje fenomen overfitting.

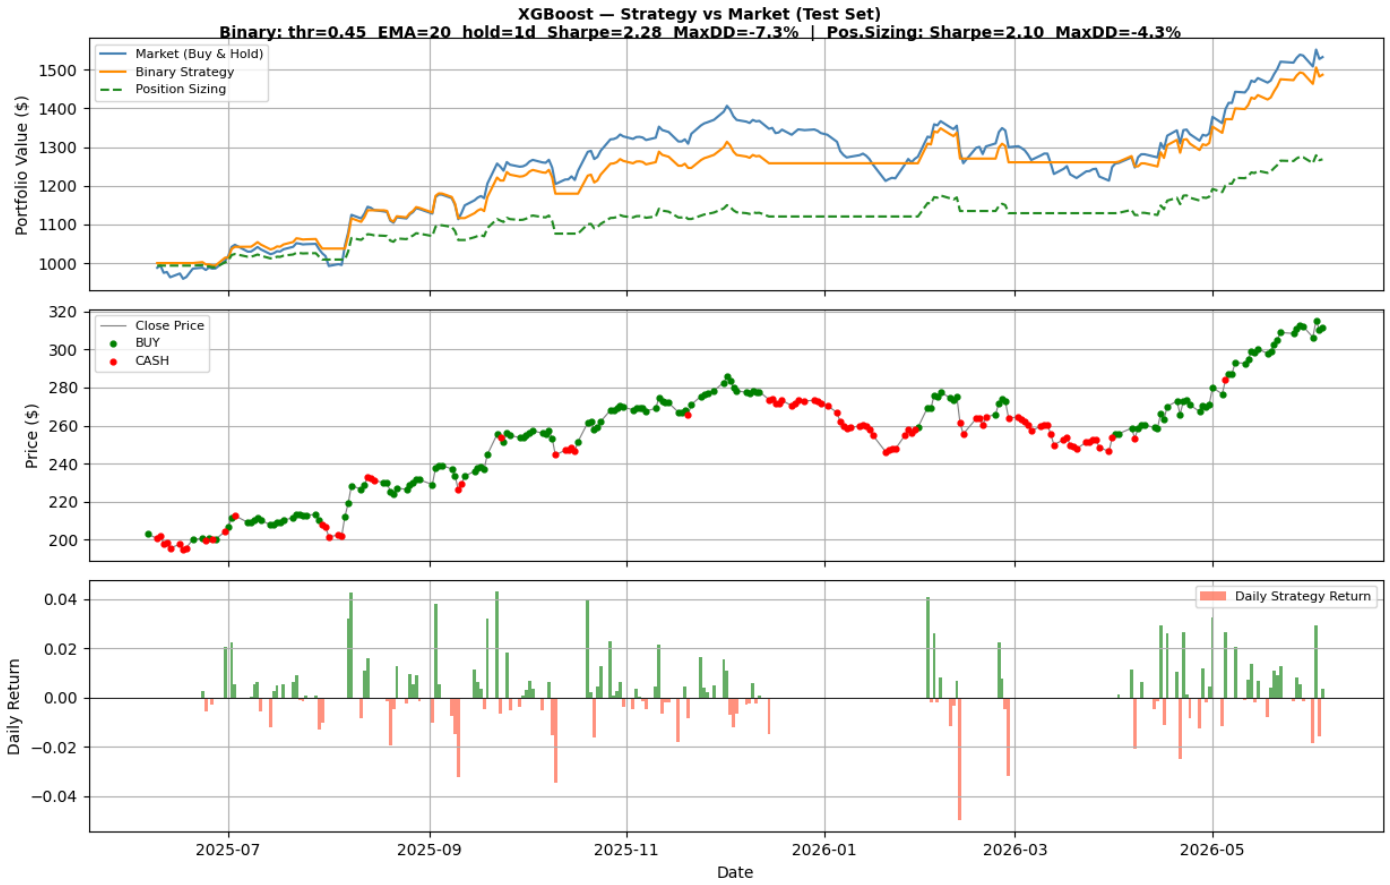


6.3. Rezultati backtestinga

Grid search na validacijskom skupu biranjem XGBoost modela i optimizacijom Sharpeovog omjera. Testni period (lipanj 2025. - svibanj 2026.) karakterizira izuzetno snažan rast AAPL dionice (52.73%).

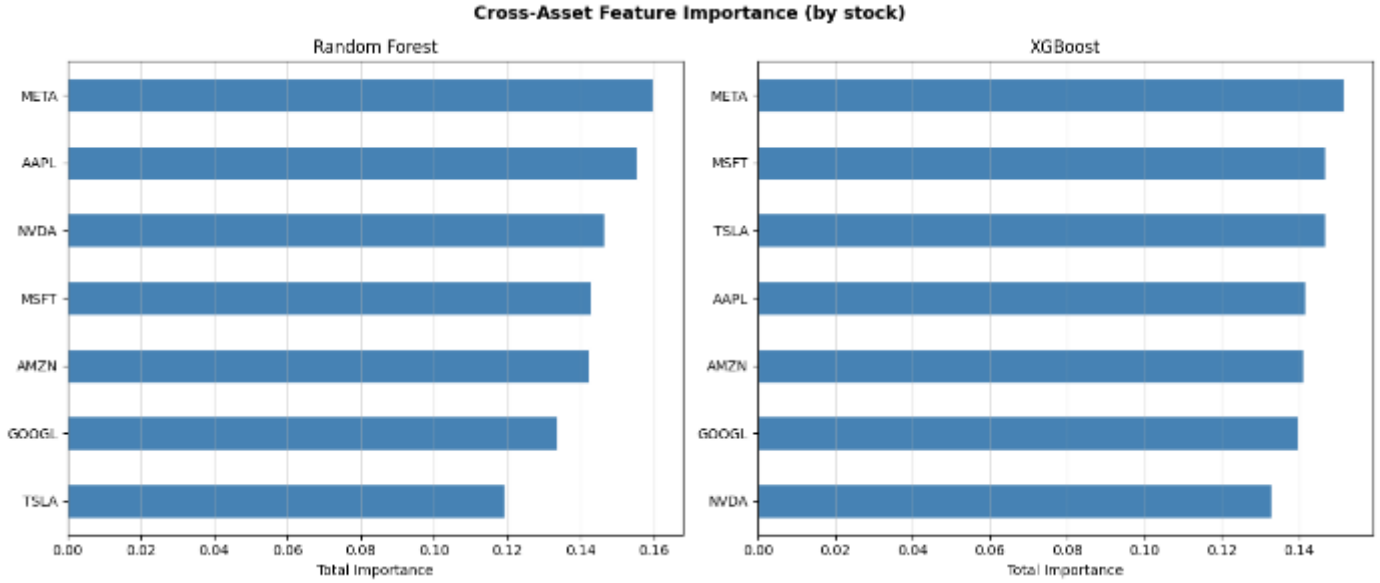
Metrika	Position Sizing	Binary	Market
Total return	26,66%	28,69%	52,73 %
Sharpe ratio	2,084	2,053	2,029
Maks. drawdown	-4,24%	-7,82%	-13,80 %

Strategija position sizing pokazuje veću robusnost: Sharpeov omjer ostaje konzistentan bez obzira na parametre odabrane gridsearchom, jer ne ovisi o fiksnom pragu. Binarna strategija je osjetljiva na odabrane hiperparametre. Obje strategije ostvaruju znatno niži maksimalni drawdown u usporedbi s pasivnim buy and hold pristupom, što znači da ML model uspješno identificira rizične periode i prebacuje kapital u gotovinu.



6.4. Važnost obilježja po dionici (XGBoost)

Agregiranjem XGBoost važnosti obilježja po dionici (suma svih 10 indikatora po dionici) dobiva se uvid u to koja dionica najviše doprinosi predviđanju AAPL:



META i MSFT dominiraju jer su korelacijski najbliži AAPL u tehnološkom sektoru. XGBoost koristi svih 7 dionica gotovo jednako dok Random Forest pokazuju nešto veće razlike.

7. ZAKLJUČAK

Razvijen je sustav za predviđanje smjera kretanja cijene AAPL dionice koji kombinira cross-asset pristup, klasične ML modele i duboko učenje. Najvažniji zaključci:

- XGBoost ostvario je 54% točnost na testnom skupu, sto je statistički značajno iznad slučajnog (50 %) uz konzistentnost s EMH.
- Cross-asset obilježja (70 indikatora iz 7 dionica) poboljsavaju signal u usporedbi s jednostrukim skupom obilježja.
- LSTM (54% točnost) potvrdio je da složenost modela ne jamči bolje rezultate
- Position Sizing strategija robusnija je od binarne strategije: Sharpeov omjer 2,084
- Obje ML strategije ostvaruju znatno niži maksimalni drawdown (-4 do -8 %) od tržišta (-13,8 %), sto potvrđuje ekonomsku korisnost modela za upravljanje rizikom.
- Primjena minimalnog perioda držanja i EMA filtera demonstrirala je važnost kombiniranja ML signala s pravilima upravljanja pozicijom.

Budući rad mogao bi uključiti: uključivanje makroekonomskih indikatora i sentimentalnih podataka, hibridne modele (XGBoost + LSTM), te proširenje strategije na short-selling za iskorištavanje i pada tržišta.

LITERATURA

[1] J. Chen et al., "A machine learning approach to stock price prediction," Procedia Computer Science, 2021.
[2] L. Breiman, "Random Forests," Machine Learning, vol. 45, pp. 5–32, 2001.
[3] T. Chen and C. Guestrin, "XGBoost: A Scalable Tree Boosting System," in Proc. KDD, 2016.
[4] S. Hochreiter and J. Schmidhuber, "Long Short-Term Memory," Neural Computation, vol. 9, no. 8, pp. 1735–1780, 1997.
[5] E. F. Fama, "Efficient Capital Markets: A Review of Theory and Empirical Work," Journal of Finance, vol. 25, no. 2, pp. 383–417, 1970.
[6] F. Pedregosa et al., "Scikit-learn: Machine Learning in Python," JMLR, vol. 12, pp. 2825–2830, 2011.
[7] M. Abadi et al., "TensorFlow: A System for Large-Scale Machine Learning," in Proc. OSDI, 2016.
[8] yfinance library — https://github.com/ranaroussi/yfinance